Limpieza del dataset Room Occupancy Estimation

Luis Manuel Velasco Iglesias · A00226599

TC5044.10 MLOps · Actividad 3: Data Wrangling

1. El problema

Un sensor que reporta 3,084 °C en una oficina no está midiendo calor: está fallando. El dataset Room Occupancy Estimation (UCI) registra cada 30 segundos la temperatura, la luz, el sonido, el CO_2 y el movimiento en una habitación para estimar cuántas personas hay en ella (de 0 a 3). Recibí una copia de 10,331 lecturas con errores típicos de los sistemas reales: formatos inconsistentes, textos en lugar de números, valores imposibles y registros duplicados. El reto fue limpiarla de forma reproducible y demostrar con evidencia qué estrategia recupera mejor la información original. Todas las decisiones se tomaron **sin mirar los datos originales**; estos se usaron solo al final, para calificar el resultado.

2. Qué encontré en los datos

Antes de modificar cualquier valor apliqué diez pruebas de diagnóstico contra un **contrato de datos**: la descripción escrita de cómo se ven los datos válidos (columnas, tipos y rangos físicamente posibles según la documentación del dataset). La Tabla 1 resume lo encontrado y la acción que justificó cada hallazgo.

Tabla 1. Problemas encontrados y acción aplicada.

Problema detectado	Magnitud	Acción
Columna de ruido sin relación con la ocupación	1 columna	Eliminada
Espacios, textos inválidos (?, error, NULL…) y celdas vacías	9,766 + 2,810 celdas	Normalizados; inválidos → faltantes
Valores físicamente imposibles (p. ej. 3,084 °C)	994 celdas	Convertidos a faltantes
Picos aislados dentro del rango (66 → 623 → 66 lux)	291 celdas	Convertidos a faltantes
Ocupación faltante o imposible (hasta 958 personas)	215 lecturas	Eliminadas: una etiqueta no se imputa
Lecturas sin fecha u hora válida	192 lecturas	Eliminadas
Lecturas registradas dos veces	182 copias	Combinadas; 66 celdas recuperadas

Dos hallazgos destacan. Primero, los duplicados estaban escondidos: comparando filas completas solo aparecía 1, pero al normalizar formatos y usar la fecha y hora como llave surgieron 189 lecturas repetidas, porque las copias diferían en alguna celda corrompida. Segundo, muchos errores caían dentro de rangos plausibles: 623 lux es una luz posible, pero no entre dos lecturas de 66 lux tomadas 30 segundos antes y después. Para

detectarlos aproveché que los datos son una serie de tiempo y comparé cada lectura con sus vecinas; esta prueba encontró más de cuatro veces los errores de luz que detectó la regla de rangos.

3. Cómo los limpié

Cada prueba se convirtió en un paso de un pipeline reproducible de nueve funciones, con una bitácora que registra cuántas filas y celdas modifica cada paso. Al final, todos los problemas se redujeron a uno: valores faltantes en el 29.4% de las lecturas. Comparé tres formas de tratarlos: **A)** eliminar las lecturas incompletas; **B)** interpolar cada faltante a partir de las lecturas anterior y siguiente de la misma sesión de medición, y **C)** reemplazarlo por la mediana de su columna. Los tres resultados pasaron una validación automática (rangos, tipos, orden temporal y ausencia de duplicados) y se guardaron como archivos separados.

4. Qué estrategia funciona mejor

Al auditar contra el original, las pruebas detectaron el **96.3%** de las 3,979 celdas corrompidas, con solo 2 falsas alarmas. Para comparar las estrategias usé como referencia el original sin duplicados y medí qué tanto se parece cada resultado (Tabla 2 y Figura 1).

Tabla 2. Similitud de cada estrategia con el original. Distancia KS: diferencia entre distribuciones (prueba de Kolmogorov-Smirnov); |SMD|: diferencia estandarizada de medias. Valores menores indican mayor parecido. En el original, el 0.11% de las lecturas con gente tiene la luz en 0.

Estrategia	Lecturas conservadas	Distancia KS media	|SMD| medio	Máx. Δ correlación (sin sonido)	Gente con luz en 0
A · Eliminar	6,876 (67.9%)	0.0072	0.0177	0.016	0.08%
B · Interpolar	**9,739 (96.1%)**	**0.0023**	**0.0111**	**0.008**	**0.11%**
C · Mediana	9,742 (96.2%)	0.0095	0.0148	0.030	2.03%

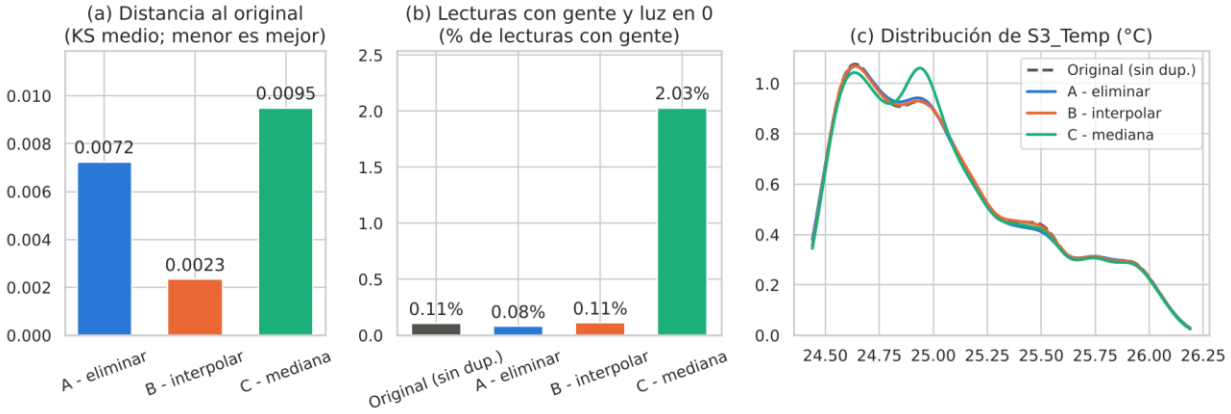


Figura 1. (a) Distancia media entre las distribuciones de cada estrategia y las del original. (b) Lecturas con gente en la habitación y la luz principal en 0. (c) Distribución de la temperatura del sensor 3: el pico verde es el valor que la mediana repite.

La interpolación temporal (B) es la estrategia que mejor preserva la información: conserva el 96% de las lecturas y tiene la menor distancia al original en todas las métricas (Figura 1a). Funciona porque, con lecturas cada 30 segundos, los valores vecinos casi no cambian. Las tres conservan la proporción de ocupación (prueba chi-cuadrada, $p > 0.86$), pero difieren en lo demás. A solo usa mediciones reales, pero pierde un tercio de los datos y deja huecos en la serie. C es la advertencia más interesante: pasa todas las validaciones, pero rellena con valores de habitación vacía (luz 0, CO_2 360 ppm) lecturas en las que había gente, lo que multiplica por 18 las contradicciones entre sensores y ocupación (Figura 1b) y crea picos artificiales en las distribuciones (Figura 1c). **Un dataset válido no es necesariamente un dataset correcto.**

5. Lo que no pude corregir

Unas 135 lecturas de sonido corrompidas no se pudieron detectar: un valor alto y aislado se parece a una voz o a un golpe reales. Llegan a las tres estrategias, por lo que los sensores de sonido quedan con una dispersión de 1.1 a 2.8 veces la original y una relación más débil con la ocupación. Además, algunos límites del contrato son supuestos razonados (por ejemplo, el voltaje máximo del micrófono) y en 12 celdas dos copias de una misma lectura no coincidían, sin forma de saber cuál era la correcta.

6. Recomendación

Recomiendo la interpolación temporal (B) para análisis y entrenamiento de modelos. En un sistema en tiempo real habría que adaptarla, porque usa la lectura siguiente, que aún no existe; ahí solo podría rellenarse con la anterior. Como siguientes pasos propongo una regla específica para el sonido (por ejemplo, comparar los cuatro micrófonos de la habitación, que deberían reaccionar juntos ante un ruido real) e integrar el contrato de datos como una validación automática antes de cada entrenamiento.